

Detección de broncoespasmos mediante análisis de audio y machine learning para integración en una plataforma de mHealth

Introducción

El presente trabajo documenta el desarrollo de un clasificador de anormalidades respiratorias destinado a ser integrado en una plataforma *mHealth*. El objetivo general del proyecto es evaluar la factibilidad de entrenar modelos de *machine learning* y *deep learning* capaces de identificar patrones respiratorios anormales a partir de grabaciones obtenidas con teléfonos celulares.

Para ello, se llevó adelante un análisis completo del pipeline de procesamiento de audio, desde la segmentación de señales respiratorias hasta la extracción de atributos y la generación de espectrogramas. Se experimentó con múltiples enfoques de preprocesamiento, segmentación y data augmentation, y se entrenaron diversos modelos (*Random Forest* y *MobileNet*) tanto sobre datos crudos como sobre datos transformados con técnicas de adaptación de dominio.

Debido a que aún no se cuenta con un dataset propio grabado con celulares, el proyecto se basó principalmente en el *ICBHI 2017 Respiratory Sound Database*, un dataset clínico ampliamente utilizado en la literatura. Esto permitió establecer una línea de base sólida y evaluar las limitaciones inherentes a entrenar modelos con datos provenientes de un dominio distinto al dispositivo objetivo. Asimismo, se incluyeron grabaciones reales obtenidas durante el proyecto como insumo exploratorio para comparar patrones espectrales y estudiar el impacto del ruido de entorno propio de un celular.

La evaluación de los modelos se realizó utilizando AUC-ROC como métrica principal, dado que permite medir la capacidad discriminativa del clasificador independientemente del umbral y es especialmente adecuada para escenarios con clases potencialmente desbalanceadas. De manera complementaria, se reportaron Recall y F1-Score como métricas auxiliares, priorizando el análisis de la sensibilidad del modelo (detección de casos positivos) y del equilibrio entre precisión y cobertura.

El resultado es un conjunto sistemático de metodologías, scripts, experimentos y modelos que sirven como infraestructura inicial para futuras etapas del proyecto. El repositorio documenta cada uno de los pasos críticos, junto con los resultados obtenidos y sus implicancias para un eventual despliegue real.

Integración prevista en la plataforma *mHealth*

Como parte del proyecto, se definieron las especificaciones necesarias para la futura integración del clasificador dentro de una plataforma mHealth. Se estableció que el sistema realizará una clasificación binaria (broncoespasmo: sí/no) basada en la detección de sibilancias y crepitaciones, respetando restricciones claves como el tamaño reducido del modelo (*on-device*) y el resguardo de la privacidad del usuario. Además, se diseñó un flujo **preliminar** de operación:

- Presentación de instrucciones al usuario (ambiente silencioso, ritmo respiratorio, posición del celular).
- Grabación aproximada de 30 segundos.
- Segmentación del audio.
- Inferencia por segmento (probabilidad o clasificación).
- Complementación con una breve encuesta sobre síntomas.
- Entrega de una salida binaria simple y comprensible (visite a su médico: sí/no).




Figura 1: Flujo tentativo de operación en la plataforma *mHealth*.

Este diseño orienta el desarrollo hacia un caso de uso realista y permite evaluar la viabilidad del despliegue en dispositivos móviles.

Dataset y procesamientos

Durante el proyecto se realizó un análisis exhaustivo de los datasets disponibles. Al evaluar la base finalmente seleccionada (*ICBHI Challenge 2017 Sound Respiratory Database*), se observó que presentaba un balance adecuado entre casos positivos y negativos de broncoespasmo, así como una distribución suficientemente equilibrada en género, lo que redujo la necesidad de aplicar técnicas de balanceo artificial. Además, no se requirió aplicar técnicas de limpieza de datos, permitiendo trabajar con información original y clínicamente consistente.

Un aporte relevante del trabajo fue la comparación sistemática entre dos enfoques de segmentación del audio:

- **Ciclos respiratorios:** Implica el desarrollo de un algoritmo de segmentación de audios en ciclos respiratorios y el uso de *padding* para igualar la duración de todos los audios (6 segundos) ya que los modelos esperan datos del mismo tamaño a través de todo el *dataset*. A pesar de esto, es el enfoque más utilizado en trabajos similares.
- **Segmentación en ventanas temporales:** Se dividieron los audios en segmentos de 4 segundos, utilizando *padding* en los segmentos que no alcancen dicha duración. También se utilizaron ventanas temporales de la misma duración con bandas mel y definición temporal necesarios para obtener una matriz 224x224, ya que este es el tamaño de imagen para el que MobileNet fue optimizada.




Figura 2: Distribución de clases en el dataset tanto para la segmentación por ciclo respiratorio como para ventanas temporales

Además, se evaluaron dos estrategias principales para procesar señales respiratorias:

- **Atributos de audio:** Incluyeron MFCCs, *zero-crossing rate*, *short time energy*, *spectral centroid*, *spectral roll-of*, *band-energy ratio* y *spectral flatness*.
- **Espectrogramas Mel:** Tanto como **imágenes** como **matrices numéricas**. Generados con 128 bandas mel y *peak normalization*.

Antes del entrenamiento de modelos, se realizó un análisis visual y auditivo de los registros. Se construyeron espectrogramas Mel (Figura 3, fila superior), donde fue posible identificar claramente patrones característicos de **sibilancias** y **crepitaciones**. Validando que estas anomalías respiratorias eran distinguibles en el dominio tiempo frecuencia y podían ser alimentadas a un modelo de ML/DL.




Figura 3: Espectrogramas Mel de ciclos respiratorios positivos (sibilancias en verde y crepitaciones en rojo), incluyendo audios reales de celular (uno de ellos excepcionalmente silencioso).

Adicionalmente, se generaron espectrogramas Mel de grabaciones reales obtenidas con un celular durante el proyecto (Figura 3, segunda fila), con el fin de comparar visualmente su estructura espectral con los audios de la base de datos. La comparación permitió observar similitudes en los patrones de las anomalías, pero también diferencias en el ruido de fondo y la respuesta en frecuencia, reforzando la importancia de obtener datos recolectados con el dispositivo final y justificando la incorporación posterior de técnicas de adaptación de dominio.

Entrenamiento de modelos con datos crudos

En primer lugar, se entrenaron modelos con audios crudos (sin *augmentation*) sobre los dos esquemas de segmentación. Los modelos seleccionados fueron *Random Forest* y *MobileNet* pre-entrenada.

La elección de estos modelos se basó en la revisión bibliográfica realizada al inicio del proyecto. Tanto *Random Forest* (RF) como *Support Vector Machines* (SVM) y arquitecturas convolucionales como *MobileNet* fueron mencionados en trabajos anteriores. Aunque se consideró entrenar un SVM, este modelo resultó poco práctico debido al tamaño del dataset y la cantidad de features extraídos. En cambio, RF ofreció un equilibrio entre desempeño, velocidad y flexibilidad a distintos inputs (atributos de audio y espectrogramas Mel).

Por otro lado, *MobileNet* se eligió debido a que está optimizada para dispositivos móviles ya que ofrece un costo computacional significativamente menor que otras CNN más pesadas. Se trabajó tanto con espectrogramas Mel en forma de imagen como de matriz numérica.

Finalmente, se evaluó la posibilidad de realizar fine-tuning de *MobileNet*, pero esta opción fue descartada porque incrementaba significativamente el tamaño del modelo final, superando los límites tolerables para su uso en un dispositivo móvil.

Modelo	Pre-procesado	Procesado	AUC-ROC	Recall	F1-Score	Acc
Random Forest	Ciclos respiratorios	Atributos de Audio	0.87	0.80	0.79	0.80
Random Forest	Ventanas Temporales	Atributos de Audio	0.85	0.79	0.78	0.77
MobileNet	Ciclos Respiratorios	Imágenes Espectrograma Mel	0.78	0.78	0.72	0.70
MobileNet	Ventanas Temporales 224x224	Espectrograma Mel	0.76	0.75	0.71	0.69
MobileNet	Ventanas Temporales	Espectrograma Mel	0.76	0.67	0.69	0.65
Random Forest	Ciclos Respiratorios	Espectrograma Mel	0.75	0.69	0.68	0.69
MobileNet	Ventanas Temporales 224x224	Imágenes Espectrograma Mel	0.73	0.73	0.70	0.68
MobileNet	Ventanas Temporales	Imágenes Espectrograma Mel	0.72	0.70	0.68	0.67
Random Forest	Ventanas Temporales	Espectrograma Mel	0.71	0.71	0.68	0.68
MobileNet	Ciclos Respiratorios	Espectrograma Mel	0.71	0.73	0.67	0.65

Tabla 1: Resultados del entrenamiento y testeo de modelos sobre datos crudos.

Los resultados (tabla 1) mostraron que:

- *Random Forest* sobre atributos de audio tuvo un **desempeño superior** al de modelos más complejos. También **superó a varios trabajos de la literatura**, entre ellos uno con modelos similares a los que se aplicaron (mismo *dataset*, modelos ligeros). La mejor métrica de ese trabajo fue una *accuracy* de 0.78 con un SVM, su RF obtuvo una *accuracy* de 0.73.
- Las ventanas temporales alcanzaron **métricas similares a los ciclos respiratorios**, presentándose como un método **viable y más simple** para el despliegue, ya que evita depender de un segmentador de ciclos. Este hallazgo es especialmente valioso para la incorporación del modelo en una plataforma de *mHealth*, ya que simplifica la arquitectura necesaria.

- Las ventanas temporales con espectrogramas Mel de tamaño 224x224 no mejoraron de manera significativa las métricas objetivo.

Entrenamiento de modelos con datos aumentados

Para aproximar las condiciones reales de uso en una aplicación móvil, se implementaron estrategias de *domain adaptation* y *data augmentation* incorporando distintos tipos de ruido (ruido blanco, ruido realista del *Microsoft Scalable Noisy Speech Dataset*, ruido real grabado con celular y desplazamientos temporales).




Figura 4: Espectrogramas Mel de audios aumentados con ruido real y comparación con audios de celular.

Los espectrogramas Mel con ruido añadidos (Figura 4) permitieron evaluar visualmente cómo se deformaban las características respiratorias frente a condiciones realistas de grabación. Se observó como **el ruido puede tapar por completo las anomalías respiratorias** cuando la intensidad del ruido es considerablemente alta (Figura 4, esquina superior derecha), dando indicios de que un modelo entrenado con estos datos aumentados no podría alcanzar el mismo desempeño que con datos crudos.

Con estos datos aumentados, se reentrenaron los modelos anteriores. Los resultados fueron similares a los obtenidos con audios crudos, con la diferencia de una importante caída en el desempeño. Los *Random Forest* entrenados con atributos de audio fueron los mejores y las ventanas temporales obtuvieron resultados cercanos a los ciclos respiratorios.

Modelo	Pre-procesado	Procesado	AUC-ROC	Recall	F1-Score	Δ AUC-ROC
Random Forest	Ciclos Respiratorios	Atributos de Audio	0.69	0.63	0.62	-20.7%
Random Forest	Ventanas Temporales	Atributos de Audio	0.67	0.70	0.66	-21.2%
Random Forest	Ciclos Respiratorios	Espectrograma Mel	0.67	0.64	0.63	-10.7%
MobileNet	Ciclos Respiratorios	Imágenes Espectrograma Mel	0.67	0.61	0.62	-14.1%
MobileNet	Ciclos Respiratorios	Espectrograma Mel	0.63	0.72	0.63	-16%
MobileNet	Ventanas Temporales	Imágenes Espectrograma Mel	0.63	0.64	0.62	-12.5%
MobileNet	Ventanas Temporales 224x224	Imágenes Espectrograma Mel	0.61	0.76	0.65	-16.4%
MobileNet	Ventanas Temporales	Espectrograma Mel	0.61	0.74	0.64	-19.7%
Random Forest	Ventanas Temporales	Espectrograma Mel	0.61	0.69	0.63	-14.1%
MobileNet	Ventanas Temporales 224x224	Espectrograma Mel	0.60	0.73	0.64	-21%

Tabla 2: Resultados del entrenamiento y testeo de modelos sobre datos aumentados.

Los resultados obtenidos con datos aumentados (Tabla 2) mostraron una **disminución considerable del desempeño** en comparación con los modelos entrenados sobre audios crudos. La diferencia entre los RF basados en atributos de audio y modelos basados en espectrogramas Mel disminuyó notablemente, lo que sugiere que los modelos basados en espectrogramas Mel tienen una mayor robustez ante el ruido introducido y, por lo tanto, no deberían ser descartados como candidatos para un modelo futuro.

Entrenamiento con audios de micrófono

Luego de evaluar el enfoque planteado inicialmente, se procedió al entrenamiento de modelos utilizando una versión filtrada del conjunto de datos original, que incluye exclusivamente los audios grabados con el micrófono AKGC417L. El objetivo de esta etapa fue analizar el desempeño de los modelos en un escenario más alineado con el tipo de señal que se espera utilizar en producción.

Modelo	Pre-procesado	Procesado	AUC-ROC	Recall	F1-Score	Acc
Random Forest	Ciclos Respiratorios	Atributos de Audio	0.89	0.89	0.85	0.82
MobileNet	Ciclos Respiratorios	Imágenes Espectrograma Mel	0.79	0.87	0.80	0.75
Random Forest	Ciclos Respiratorios	Mel Espectrograma	0.77	0.88	0.77	0.70
MobileNet	Ciclos Respiratorios	Espectrograma Mel	0.77	0.86	0.77	0.71

Tabla 3: Resultados de entrenamiento y testeo de modelos sobre audios de micrófono AKGC417L.

Los resultados obtenidos (Tabla 3) fueron superiores a los alcanzados al entrenar con el conjunto de datos entero (Tabla 1). Este comportamiento resultó inesperado ya que los registros obtenidos mediante estetoscopios suelen presentar mayor calidad acústica y, por lo tanto, deberían facilitar la detección de anomalías respiratorias. Igualmente, este hallazgo es positivo para el objetivo final del proyecto, ya que sugiere que los modelos pueden aprender patrones relevantes a partir de señales adquiridas con micrófonos.

Cabe destacar que los audios incluidos en este conjunto filtrado fueron captados en entornos controlados, con niveles de ruido significativamente menores a los que se esperan en un contexto real. Para abordar esta limitación, se decidió volver a aplicar las mismas técnicas de *data augmentation*.

Modelo	Pre-procesado	Procesado	AUC-ROC	Recall	F1-Score	Acc
Random Forest	Ciclos Respiratorios	Atributos de Audio	0.68	0.88	0.74	0.65
MobileNet	Ciclos Respiratorios	Imágenes Espectrograma Mel	0.69	0.86	0.74	0.65
Random Forest	Ciclos Respiratorios	Mel Espectrograma	0.68	0.73	0.70	0.64
MobileNet	Ciclos Respiratorios	Espectrograma Mel	0.66	0.86	0.73	0.64

Tabla 4: Resultados de entrenamiento y evaluación de modelos sobre datos aumentados y filtrados.

Al analizar los resultados obtenidos con audios aumentados, se observa una mejora clara en términos de recall en comparación con los modelos entrenados sobre el conjunto de datos completo aumentado (Tabla 2). Sin embargo, al considerar la métrica objetivo principal, AUC-ROC, las diferencias respecto a los modelos entrenados con audios crudos de micrófono no resultan significativas. Esto significa que, si bien el aumento de datos contribuye a mejorar la sensibilidad, su impacto sobre la capacidad discriminatoria es limitado y similar al observado anteriormente.

Para mitigar la caída en el desempeño de los modelos sobre datos aumentados en relación a los modelos entrenados con datos crudos se exploraron distintas técnicas adicionales durante el procesamiento para eliminar el ruido molesto:

- *Denoising* basado en sustracción espectral, *wavelet denoising*.

- Filtros pasa banda y filtros pasa bajos con distintos umbrales.
- Normalizaciones como *peak normalization*, *RMS normalization* o *amplitude normalization*.

Sin embargo, ninguna de estas estrategias produjo mejoras significativas.

Se puede concluir que si bien los modelos alcanzaron métricas razonables con audios crudos, **su capacidad de generalización hacia condiciones reales podría ser limitada**. Aunque, a pesar del uso de técnicas de *domain adaptation*, **no es posible afirmar que estas transformaciones equivalgan a entrenar con audios grabados con celulares**. Por lo tanto, las métricas obtenidas deben interpretarse con cautela.

Comparación de ciclos respiratorios y ventanas temporales

Finalmente, al momento de definir el tipo de preprocesamiento a utilizar en el *pipeline* final, resulta necesario comparar la segmentación por ciclos respiratorios y la segmentación en ventanas temporales, considerando tanto su complejidad de implementación como sus implicancias sobre el entrenamiento y el comportamiento de los modelos.

En primer lugar, la segmentación en ciclos respiratorios requiere la incorporación de un componente adicional en el *pipeline*: un segmentador, ya sea un algoritmo o un modelo, capaz de identificar con precisión los comienzos y finales de cada ciclo respiratorio presentes en el audio de entrada.




Figura 5: Ejemplo de funcionamiento del segmentador por ciclos respiratorios, donde cada ciclo se resalta en gris.

Este requisito incrementa la complejidad general del sistema y agrega una posible fuente adicional de error, ya que el desempeño del modelo final queda condicionado por la calidad de la segmentación.

Por el contrario, la segmentación en ventanas temporales presenta una menor complejidad de implementación, dado que no requiere de la existencia de un segmentador.

Sin embargo, la segmentación en ventanas temporales introduce una desventaja relevante: una anomalía respiratoria puede quedar dividida entre dos ventanas consecutivas, lo que dificulta su correcta representación y puede afectar el cálculo de la salida final (Figura 1). En contraste, los ciclos

respiratorios contienen las anomalías en su totalidad, preservando la estructura temporal completa del evento de interés.

Desde el punto de vista del aprendizaje del modelo, se observaron diferencias adicionales. Al entrenar modelos utilizando espectrogramas Mel correspondientes a ciclos respiratorios, algunos algoritmos tienden a asignar menor importancia a las regiones ubicadas en los bordes del espectrograma, como se muestra en el mapa de importancia de *features* de la Figura 6. Este comportamiento está relacionado con la variabilidad en la duración de los ciclos y con la necesidad de realizar *padding*.




Figura 6: Mapa de importancia de features de un RF entrenado con espectrogramas Mel de ciclos respiratorios.

En cambio, los modelos entrenados con ventanas temporales fijas muestran una atención más uniforme sobre todo el espectrograma (Figura 7), lo que sugiere una exploración más homogénea de la información espectral disponible.




Figura 7: Mapa de importancia de features de un RF entrenado con espectrogramas Mel de ventanas temporales.

En resumen, la segmentación por ciclos respiratorios ofrece la ventaja de preservar la integridad temporal de las anomalías, a costa de una mayor complejidad del *pipeline* y una mayor dependencia de la calidad de la segmentación. Por su parte, la segmentación en ventanas temporales simplifica la implementación y favorece una utilización más uniforme de las *features*, aunque introduce el riesgo de fragmentar eventos relevantes. La elección entre ambos enfoques debe balancear estas consideraciones en función de los requisitos de robustez, simplicidad y generalización del sistema final.

Conclusión

Los experimentos realizados con los modelos entrenados (Random Forest y MobileNet aplicados sobre representaciones Mel y sobre atributos de audio) mostraron resultados prometedores en la detección de broncoespasmos. Su desempeño, evaluado mediante AUC-ROC como métrica principal y Recall y F1-Score como métricas auxiliares, confirma el potencial de estas arquitecturas para identificar patrones respiratorios anormales. Estos hallazgos se alinean con el objetivo central de este trabajo de investigación aplicada.

En síntesis, las prácticas realizadas permitieron extraer conclusiones relevantes sobre la **factibilidad** de detectar broncoespasmos utilizando modelos entrenados con audios provenientes de dispositivos **distintos** a los de uso final.

Este trabajo constituye una **base metodológica sólida** para entrenar un modelo de producción en caso de obtener en el futuro un *dataset* grabado específicamente con teléfonos celulares. La infraestructura desarrollada permite replicar experimentos, incorporar nuevos datos y adaptar fácilmente los componentes del *pipeline*.