

Detección de broncoespasmos mediante análisis de audio y *machine learning* para integración en una plataforma de *mHealth*

Alumno: Nazareno Magallanes

Director: Ignacio Fenoy

Tutor: Homero Lozza

Introducción

Descripción general

Este proyecto propone desarrollar un modelo de inteligencia artificial (IA) capaz de detectar signos de broncoespasmo a partir de grabaciones de tos y respiración enviadas desde teléfonos celulares. El modelo se integrará en una plataforma de *mHealth* que incluye un inhalador inteligente y una app móvil, desarrollada para mejorar la adherencia y seguimiento de pacientes con enfermedades respiratorias (como asma y EPOC). El modelo permitirá alertar al paciente en caso de signos sugestivos de broncoespasmo, ayudando a decidir si es necesario intensificar su tratamiento o consultar con un profesional médico.

Objetivos del proyecto

- Diseñar un pipeline de procesamiento de audio respiratorio.
- Entrenar y validar modelos de clasificación (ML/DL) para detectar broncoespasmo.
- Utilizar bases de datos públicas abiertas recopiladas durante la pandemia (ej. COUGHVID, Coswara, ICBHI)
- Desarrollar una API o prototipo funcional para probar el modelo con grabaciones nuevas.
- Documentar el proceso de desarrollo y generar entregables para evaluación.

Actividades a realizar

1. Investigación Inicial
2. Definición de las especificaciones del proyecto para su integración en la plataforma *mHealth*
3. Revisión y elección de datasets
4. Procesamiento de datos
5. Entrenamiento de modelos
6. Integración con la plataforma/app
7. Documentación

Elección dataset


- Se exploraron distintas bases de datos públicos relacionados con sonidos respiratorios:
 - COUGHVID
 - Coswara
 - ICBHI Challenge 2017 Sound Respiratory Database
 - SPRSound
 - HF Lung
- La evaluación incluyó análisis de etiquetas disponibles, equilibrio de clases, instrumentos de grabación empleados y metadata clínica asociada a pacientes y voluntarios.
- Se eligió la **ICBHI Challenge 2017 Sound Respiratory Database (RSDB)** debido a que incluye registros obtenidos con micrófonos más cercanos a las condiciones esperadas en la plataforma *mHealth*.

RSDB

- Audios grabados con micrófono y estetoscopios
- División en ciclos respiratorios
- Etiquetas para crepitaciones y sibilancias
- 920 audios, 6898 ciclos respiratorios, 126 pacientes
- 3256 ciclos contienen anomalías (1864 contienen crepitaciones, 886 contienen sibilancias, and 506 contienen ambos)
- Metadata: Edad, Sexo, BMI (kg/m²), Peso niño (kg), Altura niño (cm)
- Diagnosis: EPOC, Infección del Tracto Respiratorio Superior (ITRS), Infección del Tracto Respiratorio Inferior (ITRI), entre otros.
- Localización del instrumento: Tráquea, Anterior izquierda, Anterior derecha, Posterior izquierda, Posterior derecha, Lateral izquierda, Lateral derecha
- Modo de adquisición: secuencial / canal único, simultanea / multicanal

Especificaciones

- Se decidió desarrollar un sistema de clasificación binaria (broncoespasmo: sí/no) e identificar específicamente los signos respiratorios de interés: **crepitaciones** y **sibilancias**.
- Se definieron restricciones técnicas, como el tamaño del modelo y privacidad del usuario.
- Métricas: AUC-ROC, Recall, F1-Score.
- Se diseñó un flujo tentativo para una futura integración en la plataforma:



Trabajos relevantes

Dataset	Procesamientos	Modelos	KPIs
Privado, Smartphones	Bag-of-Words To Features	SVM	Acc: 75.21%
RSDB + privado	Padding, STFT, Spectrum Correlation, Log-Mel Spectrograms, Normalization	ResNet	Sens: 76.33% Spec: 78.86%
RSDB	Time Statistics and Frequency features	ANN, SVM, RF	Acc: NN: 73%, RF: 73%, SVM: 78.3%
RSDB	Fluid-Solid Modeling, Recording Simulation, Downsampling, Feature Extraction	VGG-16	Sens: 28% Spec: 81%
RSDB	RMS Norm, Peak Norm, EBU Norm, Data Augmentation	2D CNN	Acc: 88%

Procesamiento - *Feature Extraction*

Se implementó un *transformer* personalizado de *scikit-learn* para extraer los siguientes atributos de audio:


- Dominio temporal:
 - **zero-crossing rate (ZCR)**: Mide cuántas veces la señal cruza el cero en un intervalo corto.
 - **short time energy**: Calcula la energía de la señal en ventanas cortas.
- Dominio frecuencial:
 - **40 MFCCs**: Describen la forma del espectro en escala de Mel, parecida a la percepción humana.
 - **spectral centroid**: Centro de masa del espectro, la frecuencia alrededor de la cual se concentra la energía.
 - **spectral roll-off**: Frecuencia por debajo de la cual se acumula un porcentaje fijo (85%) de la energía espectral total.
 - **band-energy ratio**: Calcula qué proporción de la energía total del espectro está por debajo de 1000 Hz.
 - **spectral flatness**: Relación entre la media geométrica y la media aritmética del espectro.

Procesamiento - Espectrogramas Mel

Se implementaron *transformers* para transformar las señales en espectrogramas en escala Mel, similar a la percepción humana:


- **MelSpectrogramTransformer:** Transforma la señal en una matriz que representa el espectrograma Mel normalizado usando *peak normalization*.
- **SpectrogramPadder:** Agrega *padding* donde sea indicado (en este caso al final y al comienzo).
- **FlattenTransformer:** Simplemente aplanar la matriz para poder alimentar modelos de ML.

Además de usar la **matriz numérica**, se usaron **imágenes** generadas a partir del plot de las mismas.



Preprocesamiento


- Se realizaron dos estrategias fundamentales de segmentación del audio:
 - Segmentación en ciclos respiratorios, utilizando las anotaciones oficiales de ICBHI, con padding a 6 para los espectrogramas.
 - Segmentación alternativa en ventanas temporales, como posible reemplazo del segmentador basado en ciclos. Se evaluaron ventanas de 4 segundos.




Preprocesamiento - Ciclos respiratorios

Para los espectrogramas Mel necesitamos que todos los audios tengan la misma duración. Para eso se empleó *padding* al comienzo y al final de cada audio menor a 6 segundos de duración. Además, esta segmentación implica la necesidad de incluir un segmentador de audios, un identificador de ciclos respiratorios.

Ejemplo de ciclo respiratorio con *padding*




Ejemplo de funcionamiento del segmentador




Preprocesamiento - Ventanas temporales

Con ventanas temporales ya no necesitamos usar *padding* la mayoría de las veces, sólo con el segmento final de los audios. Ya no es necesario un segmentador en el *pipeline*. Como los audios son en promedio más cortos podemos agregar definición temporal (menor *hop_length*) sin disminuir tanto el rendimiento durante el entrenamiento.

Ejemplo de ventana con *padding*




Ejemplo de ventana sin *padding*




Preprocesamiento - Ventanas 224x224

Uno de los modelos que usamos (MobileNet) fue optimizado para imágenes cuadradas de 224x224 píxeles. Creamos un dataset con ventanas temporales de ese tamaño ajustando la definición temporal y frecuencial de manera acorde (hop_length, n_mels). Son las mismas ventanas de antes, misma duración.

Ejemplo de ventana cuadrada sin *padding*



Ejemplo de ventana cuadrada con *padding*



Modelos candidatos

De la bibliografía obtenemos los siguientes modelos:

- *Random Forest* sobre espectrogramas Mel
- *Random Forest* sobre características de audio
- SVM sobre características de audio
- *MobileNetV2* sobre espectrogramas Mel

SVM demostró ser muy lento para entrenar, probablemente por la cantidad características y registros, no se continuó con este modelo.

MobileNetV2 es una CNN para clasificar imágenes optimizada para dispositivos móviles. Se hizo *transfer learning* con este modelo, se reemplazó el último bloque por uno personalizado con salida binaria.

Se descartó la opción de hacer *fine-tuning* a la red neuronal ya que aumenta su tamaño por encima del límite estipulado.





Modelos con datos crudos

Modelo	Pre-procesado	Procesado	AUC-ROC	Recall	F1-Score	Acc
Random Forest	Ciclos respiratorios	Atributos de Audio	0.87	0.80	0.79	0.80
Random Forest	Ventanas Temporales	Atributos de Audio	0.85	0.79	0.78	0.77
MobileNet	Ciclos Respiratorios	Imágenes Espectrograma Mel	0.78	0.78	0.72	0.70
MobileNet	Ventanas Temporales 224x224	Espectrograma Mel	0.76	0.75	0.71	0.69
MobileNet	Ventanas Temporales	Espectrograma Mel	0.76	0.67	0.69	0.65
Random Forest	Ciclos Respiratorios	Espectrograma Mel	0.75	0.69	0.68	0.69
MobileNet	Ventanas Temporales 224x224	Imágenes Espectrograma Mel	0.73	0.73	0.70	0.68
MobileNet	Ventanas Temporales	Imágenes Espectrograma Mel	0.72	0.70	0.68	0.67
Random Forest	Ventanas Temporales	Espectrograma Mel	0.71	0.71	0.68	0.68
MobileNet	Ciclos Respiratorios	Espectrograma Mel	0.71	0.73	0.67	0.65

- Características de audio superior a espectrogramas
- Ventanas temporales obtuvieron métricas similares a los ciclos respiratorios. Esto es bueno porque podríamos descartar la necesidad de un segmentador.
- Las ventanas “cuadradas” no presentan una mejora significativa por sobre las otras.

Evaluación - RF + atributos + ciclos

Modelo	Pre-procesado	Procesado	AUC-ROC	Recall	F1-Score	Acc
Random Forest	Ciclos respiratorios	Atributos de Audio	0.87	0.80	0.79	0.80




- La distribución de probabilidad es bastante plana y disminuye en los extremos. Lo que buscamos es una forma de “U”, con los extremos más altos que el centro.
- Al comparar con el trabajo más similar de la bibliografía, vemos mejores resultados.

Acc: NN: 73%, RF: 73%, SVM: 78.3%

Evaluación - Espectrogramas Mel + RF

Mapa de importancia - Ciclos vs Ventanas



RF debería tener problemas para identificar anomalías en los extremos del espectrograma cuando se usan ciclos respiratorios.


Procesamiento - *Data augmentation*

Para intentar acercar los audios que tenemos a los que recibirá el futuro modelo debemos adaptarlos al dominio de los celulares. Para esto probamos con agregar ruido a los audios de la siguiente manera:


- Ruido blanco con intensidad media aleatoria
- Ruido real con alta intensidad
- Ruido real con media intensidad
- Ruido real con baja intensidad

De esta manera cuadruplicamos la cantidad de datos lo que ocasiona un mayor costo computacional en el entrenamiento.


Espectrograma Mel original



Espectrograma Mel con ruido



Espectrograma Mel audios de celular







Modelos con datos *augmented*

Modelo	Pre-procesado	Procesado	AUC-ROC	Recall	F1-Score	Δ AUC-ROC
Random Forest	Ciclos respiratorios	Atributos de Audio	0.69	0.63	0.62	-20.7%
Random Forest	Ventanas Temporales	Atributos de Audio	0.67	0.70	0.66	-21.2%
Random Forest	Ciclos Respiratorios	Espectrograma Mel	0.67	0.64	0.63	-10.7%
MobileNet	Ciclos Respiratorios	Imágenes Espectrograma Mel	0.67	0.61	0.62	-14.1%
MobileNet	Ciclos Respiratorios	Espectrograma Mel	0.63	0.72	0.63	-16%
MobileNet	Ventanas Temporales	Imágenes Espectrograma Mel	0.63	0.64	0.62	-12.5%
MobileNet	Ventanas Temporales 224x224	Imágenes Espectrograma Mel	0.61	0.76	0.65	-16.4%
MobileNet	Ventanas Temporales	Espectrograma Mel	0.61	0.74	0.64	-19.7%
Random Forest	Ventanas Temporales	Espectrograma Mel	0.61	0.69	0.63	-14.1%
MobileNet	Ventanas Temporales 224x224	Espectrograma Mel	0.60	0.73	0.64	-21%

- Disminución importante en el desempeño general.
- Mayor disminución en modelos con atributos de audio
- Menor disminución en modelos basados en espectrogramas, más robustos.
- Hay mayor diferencia entre ciclos respiratorios y ventanas temporales.
- Se probaron técnicas de denoising y filtrado para mejorar este desempeño pero no se observaron mejoras.

Evaluación - RF + atributos + ciclos


Modelo	Pre-procesado	Procesado	AUC-ROC	Recall	F1-Score	Δ AUC-ROC
Random Forest	Ciclos respiratorios	Atributos de Audio	0.69	0.63	0.62	-20.7%




Evaluación - RF + Espec. Mel + Ciclos

Random Forest	Ciclos Respiratorios	Espectrograma Mel	0.67	0.64	0.63	-10.7%
---------------	----------------------	-------------------	------	------	------	--------


Mapa de importancia de features del modelo




Distribución de probabilidades predichas por el Random Forest




Curva ROC del Random Forest



Curva de Precisión-Recall del Random Forest



Matriz de Confusión del Random Forest



Conclusiones

Los modelos entrenados mostraron resultados prometedores en la detección de broncoespasmos con audios crudos. Pero su **capacidad de generalización** hacia condiciones reales podría ser **limitada**.

A pesar del uso de técnicas de *domain adaptation*, **no es posible afirmar que estas transformaciones equivalgan a entrenar con audios grabados con celulares**. Por lo tanto, las métricas obtenidas deben **interpretarse con cautela**.

Por todo lo mencionado anteriormente no vale la pena continuar hacia la fase de integración del modelo en la plataforma *mHealth*.

Este trabajo constituye una **base metodológica sólida** para entrenar un modelo de producción en caso de obtener en el futuro un *dataset* grabado específicamente con teléfonos celulares.

Documentación

- Docstrings
- Drive del proyecto
- Repositorio de Github
- Informe completo
- Métricas y parámetros
- Procesamientos

```
class SpectrogramPadder(BaseEstimator, TransformerMixin):
    def __init__(self, max_length=MAX_LENGTH, mode=PADDING_MODE, pad_value=None):
        '''Transformador para aplicar padding o recorte a espectrogramas de Mel.
        Parámetros:
        - max_length: Longitud máxima deseada (número de frames).
        - mode: Modo de padding/recorte ('end', 'start', 'center').
        - pad_value: Valor de padding. Si es None, se usa el valor mínimo del espectrograma.
```

preproc	hop_length	n_mels	n_fft	duración	n_mfcc	padding	sr
ciclos	256	128	1028	1 - 6	40	centrado	16000
ventanas	128	128	1028	4	40	centrado	16000
ventanas 224x224	286	224	1028	4		centrado	16000

Modelo	Datos	Datos	Transformacion	max_features	max_depth	min_samples_split	min_samples_leaf
Random Forest	Ciclos	Crudos	Atributos de Audio	None	18	15	5
Random Forest	Ventanas	Crudos	Atributos de Audio	None	14	15	7
Random Forest	Ciclos	Crudos	Mel Espectrograma	sqrt	14	26	12
Random Forest	Ventanas	Crudos	Mel Espectrograma	sqrt	15	10	5
Random Forest	Ciclos	Aug	Atributos de Audio	None	20	10	5
Random Forest	Ventanas	Aug	Atributos de Audio	None	22	19	7
Random Forest	Ciclos	Aug	Mel Espectrograma	sqrt	20	20	10
Random Forest	Ventanas	Aug	Mel Espectrograma	sqrt	20	15	5

data_preprocesada
data_procesada
dataset
modelos_clasicos
neural_network
segmentador
transformers
utils
.gitignore
Informe.pdf
README.md
config.py
evaluacion_modelos.ipynb
requirements.txt

Próximos pasos / mejoras

Mejoras a agregar hasta fin de año:

1. *Dataset* filtrado (solo microfono) - crudos y aumentados
2. Documentar intento con filtro, *denoising* y demas
3. Modelo multiclase
4. Elección de *features*
5. Ciclos respiratorios con mayor definición temporal

Posibles futuros proyectos:

1. Repetición con audios de celulares.
2. Modelo de detección de ciclos respiratorios (segmentador)
3. Modelo de detección pasiva de tos (reemplazo de parte del formulario de síntomas)